PROPUESTA DE TRABAJO FINAL
INTELIGENCIA COMPUTACIONAL

Título del Proyecto: Detección de anomalías en satélites

Integrantes: Barbero Agustín, Ciorciari Conrado.

Definición del Problema y Motivación

Contexto
Un satélite en órbita opera en un entorno extremo y hostil (radiación solar, ciclos térmicos abruptos por eclipses, vacío espacial). Dado que el mantenimiento físico es imposible una vez lanzado, la supervisión de la nave depende exclusivamente de la telemetría que son flujos continuos de datos provenientes de cientos de sensores a bordo (temperaturas, corrientes eléctricas, voltajes de baterías, velocidades de ruedas de reacción, presiones de propelente).

Históricamente, las agencias espaciales monitorean estos sensores mediante umbrales estáticos prefijados . Si un sensor supera un valor máximo o cae por debajo de un mínimo, se dispara una alarma.

Sin embargo, este enfoque tradicional presenta ciertas falencias, como lo son:
1. Anomalías dentro de rango: la mayoría de las fallas incipientes ocurren dentro de los límites normales (por ejemplo, una señal que se congela en un valor fijo, ruido de alta frecuencia que indica degradación mecánica, o derivas lentas de temperatura).
2. Dependencias multivariadas y contexto: ciertos valores son normales bajo determinadas condiciones operativas (por ejemplo, baja corriente de panel solar durante un eclipse), pero completamente anómalos bajo otras (luz solar directa). Los umbrales fijos no tienen memoria ni capacidad de correlacionar múltiples variables simultáneamente.
3. Escala temporal: El volumen masivo de datos acumulado durante años de misión hace inviable la inspección humana sin el auxilio de sistemas inteligentes automatizados.

Objetivo del Proyecto

Desarrollar un sistema de detección temprana de anomalías y monitoreo de salud del satélite basado en Inteligencia Computacional. El modelo aprenderá el comportamiento físico y operativo normal del satélite de manera semi-supervisada. Cuando ocurra una degradación o falla que rompa las dinámicas aprendidas, el sistema alertará automáticamente y permitirá visualizar el cambio de estado operativo en un espacio bidimensional interpretable.

Base de Datos: ESA Anomaly Dataset

Para validar la propuesta se utilizará el **ESA Anomaly Dataset**, un conjunto de datos real, de gran escala y recientemente publicado, resultado de un proyecto conjunto entre la Agencia Espacial Europea (ESA - European Space Operations Centre), Airbus Defence and Space y KP Labs.

Características de los datos (Misión 1)
Origen: Telemetría real de vuelo recolectada a lo largo de 14 años de operación en órbita (período 2000–2013).
Frecuencia de muestreo: mediciones periódicas registradas aproximadamente cada 90 segundos, totalizando más de 10 millones de muestras temporales por canal.
Estructura de canales: cuenta con 76 canales organizados por subsistemas funcionales (potencia/baterías, control térmico, comunicaciones, orientación y actitud - AOCS) y tipos de magnitudes físicas.
Canales Objetivo (Target): la base identifica explícitamente cuáles canales corresponden a variables críticas supervisadas y cuáles actúan como variables auxiliares de contexto.
Etiquetas de terreno (Ground Truth): se dispone de un catálogo curado por ingenieros de operaciones espaciales con más de 3.500 eventos etiquetados con marcas de tiempo exactas (`StartTime` y `EndTime`), clasificando anomalías reales, eventos operativos poco frecuentes (Rare Events) y pérdidas de enlace (Communication Gaps).

Subconjunto seleccionado para el proyecto:

Para asegurar un entrenamiento ágil, riguroso y computacionalmente eficiente, nos enfocaremos en un subsistema crítico (Subsistema 5 / Grupo funcional 8):
Canal Objetivo Principal (Target): '*channel 41'*, el cual contiene un historial representativo con más de 200 anomalías reales catalogadas por la ESA.
Canales de Soporte Multivariado: canales correlacionados del mismo subsistema (*'channel 42' y 'channel 43'*), que comparten la misma unidad física y dinámica operativa.
Canal de Contexto Global: un canal representativo del estado general de la nave (`*channel 1*`).
Ventana Temporal de Estudio: se seleccionará un período acotado y representativo (por ejemplo, el intervalo 2004–2005), reservando una fase inicial libre de fallas para el entrenamiento y una fase posterior con eventos anómalos reales para la evaluación.

La elección de este subconjunto de variables y del rango temporal responde a las siguientes problemáticas:

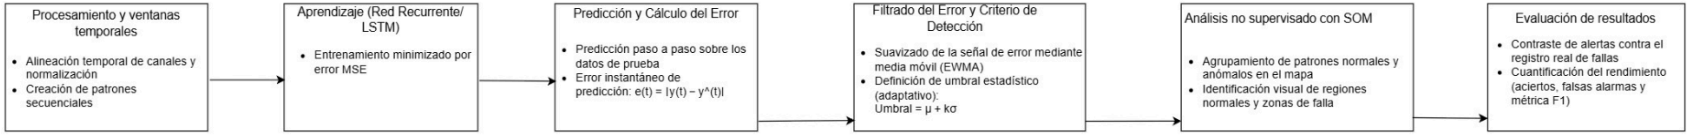
1. **Densidad de datos:** en series temporales de larga duración, muchas variables presentan cero o muy escasas anomalías (apenas 1 a 3 eventos en 14 años), lo que impide una evaluación confiable. El grupo de canales 41 al 46 contiene la **mayor concentración de anomalías certificadas de toda la misión (más de 200 eventos etiquetados cada uno)**. Esto garantiza una masa crítica suficiente para calcular métricas de evaluación con validez estadística real.
2. **Coherencia física y acoplamiento de partes:** los modelos predictivos multivariados requieren que las variables de entrada guarden una relación física genuina entre sí. Los canales 41, 42 y 43 pertenecen al mismo subsistema (subsystem 5), comparten la misma unidad física (physical unit 4) y el mismo grupo funcional (Group 8).

Monitorean componentes interconectados, permitiendo a la red capturar correlaciones físicas reales.

3. **Estabilidad numérica y variables continuas:** A diferencia de canales discretos o categóricos, los canales del grupo 8 son señales analógicas continuas pre-escaladas en el rango [0,1], lo que asegura estabilidad durante el entrenamiento por retropropagación sin requerir transformaciones forzadas.
4. **Incorporación de contexto global (channel 1):** Proviene del Subsistema 1 (Grupo 1) y **funciona como señal de referencia del estado general de la nave.** Permite al modelo discriminar si una desviación es una falla localizada del Subsistema 5 o si responde a una condición ambiental global que afectó a todo el satélite.
5. **Justificación del recorte temporal (período 2004–2005):**
    - **Viabilidad computacional:** Los 14 años representan más de 15 millones de puntos por canal, lo que generaría tensores de decenas de gigabytes y tiempos de entrenamiento prohibitivos e innecesarios para validar la arquitectura.
    - **Preservación de la estacionariedad (Envejecimiento de la nave):** En el espacio, los satélites sufren degradación natural paulatina (radiación cósmica sobre celdas solares, desgaste mecánico). Teniendo en cuenta esto, utilizamos una ventana temporal de entre 1 a 2 años que asegura la estacionariedad.
    - **Balance experimental:** El intervalo seleccionado nos proporciona datos de entrenamiento y validación, seguido de varios eventos anómalos para hacer el test.

Metodología y Plan de Desarrollo Paso a Paso

El desarrollo del trabajo se estructurará en seis etapas metodológicas consecutivas:



Para este modelo vamos a utilizar una red recurrente LTSM para aprovechar la capacidad de memoria que poseen estas para así poder entrenar un modelo el cual calcule las salidas a partir de los datos actuales como de lo que predijo en el estado anterior.
Para entrenar este modelo vamos a usar una forma peculiar, ya que no vamos a entrar en lo típico de usar datos los cuales tienen anomalías para que el modelo sepa clasificarlos segun solamente de si el dato supera un umbral o no, ya que cuando hablamos del espacio, las fallas futuras son casi siempre imprevistas y nuevas (ej: un micrometeorito impacta un panel, un chip se quema por un rayo cósmico, etc.), por lo tanto si entrenamos el modelo solo con fallas que ya conocemos, el día que ocurra una nueva falla con una forma distinta, la red va a pensar que es normal y el satélite se puede perder. También tuvimos en cuenta que de nuestros datos, los satélites el 99.5% del tiempo operan en régimen sano y las fallas solo representan menos del 0.5% por lo que la red podría aprender a clasificar siempre 0 (normal) y nunca detectar una sola falla teniendo un 99.5% de exactitud. Por último hay otro tema a tener en consideración y es que la gran mayoría de fallas críticas ocurren dentro de los límites estipulados para los datos, por ejemplo, fallas de congelamiento, si un sensor se rompe y queda trabado dentro del rango permitido, un umbral directo sobre el sensor jamás lo detectan, o tambien depende del contexto, una corriente de 2 Amperes puede ser perfecta cuando el satélite está en pleno eclipse, pero si el satélite está apuntando al sol debería generar 10 Amperes, un umbral fijo no sabe si el satélite está al sol o la sombra, en cambio la red LSTM si lo sabe por la historia temporal de los canales asociados.

Por lo tanto vamos a entrenar un modelo con datos telemétricos normales, es decir, sin anomalías, ya que lo que buscamos es que nuestro modelo pueda predecir el próximo dato que transmita el sensor, el cual debería estar operando de manera normal, y poder compararlo en tiempo real con el dato que realmente midió el sensor (calculamos el error), entonces si la medición real es similar, el error debería dar cerca de cero por lo que significa que no hay fallas en la medición del sensor, pero si ese error se dispara y supera el umbral, es porque este está fallando y estamos en presencia de una anomalía.

Paso 1: Preprocesamiento y Segmentación Temporal

1. Limpieza y normalización: Se cargan las series temporales seleccionadas, verificando la consistencia del índice temporal y escalando los datos continuos al rango $[0, 1]$.

2. Generación de ventanas: Para que una red neuronal capture la dependencia temporal, se transforma la serie continúa en pares ordenados de entrada/salida. Definiendo una ventana histórica de tamaño L (por ejemplo, $L = 50$ pasos temporales):

Entrada (X_t): Vector multivariado con las lecturas de los canales desde $t - L$ hasta $t - 1$.

Salida esperada (y_t): Valor del canal objetivo en el instante presente t.

3. Partición temporal de los datos: A diferencia de problemas estáticos donde los datos se mezclan aleatoriamente , aquí se respeta estrictamente el orden cronológico:

Conjunto de Entrenamiento / Validación: Segmento temporal inicial donde los datos telemétricos serian normales, sin anomalias.

Conjunto de Test: Segmento temporal posterior donde ocurren las anomalías documentadas en `*labels.csv*`.

Paso 2: Modelado Dinámico y Aprendizaje del Régimen Normal

1. Arquitectura: Se diseñará una red neuronal recurrente basada en celdas LSTM (o una red recurrente tipo Elman / TDNN) capaz de retener memoria de corto y largo plazo de las dinámicas físicas del satélite.

2. Función de Pérdida (Error Cuadrático Medio - MSE):

$$MSE = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2$$

Se entrena la red para predecir el valor futuro $\hat{y}_t$ a partir del historial. El MSE penaliza cuadráticamente las discrepancias, garantizando que el modelo ajusta sus pesos hasta que las trayectorias predichas copien con alta fidelidad el comportamiento físico normal.

3. Criterio de convergencia: Se utiliza parada temprana (early stopping) monitoreando la pérdida sobre el conjunto de validación para prevenir sobreajuste (overfitting).

Paso 3: Predicción y cálculo de error

1. Durante la fase de prueba (Test), el modelo recibe la telemetría en tiempo real simulado y genera la predicción un paso hacia adelante ($\hat{y}_t$).

2. Se calcula el residuo o error de predicción instantáneo:

$$e_t = |y_t - \hat{y}_t|$$

3. Fundamento del método:

Cuando el satélite opera en condiciones normales, la red predice con alta precisión, por lo que $e_t \approx 0$.

Ante la aparición de una falla, rotura o degradación, la dinámica de la señal cambia drásticamente respecto de lo aprendido. La red no puede anticipar este comportamiento y el residuo se incrementa abruptamente.

Paso 4: Filtrado del Error y Criterio de detección

1. Suavizado EWMA (Exponentially Weighted Moving Average):

Las lecturas de sensores satelitales contienen ruido instrumental de alta frecuencia que puede generar picos transitorios de error en un único instante. Para evitar falsas alarmas, se aplica una media móvil ponderada exponencialmente:

$$s_t = \alpha \cdot e_t + (1 - \alpha) \cdot s_{t-1}$$

Donde $\alpha \in (0, 1)$ es el factor de suavizado. Este filtro otorga inercia a la curva de error, de modo que sólo las desviaciones que se sostienen en el tiempo logran elevar el valor de s_t.

2. Umbral Dinámico de Decisión:

Se calcula la media (μ_0) y la desviación estándar (σ_0) de los errores residuales obtenidos durante el régimen normal. Se define el umbral de detección como:

$$Umbral = \mu_0 + k \cdot \sigma_0$$

(donde k es un coeficiente de sensibilidad, típicamente $k \in [3, 4]$).

3. Clasificación binaria:

Ct será igual a 1 si el s(t)>Umbral, es decir, se presenta una anomalía.
Ct será igual a 0 si s(t)<=Umbral,es decir, no hay anomalía.

Paso 5: Análisis no supervisado con SOM

Para complementar la detección con una herramienta de diagnóstico visual e interpretabilidad:

1. **Entrenamiento de SOM 2D:**
   Se entrena un mapa auto-organizativo bidimensional utilizando como patrones de entrada los vectores conformados por los valores multivariados de los canales y su error residual.
2. **Preservación topológica y agrupamiento no supervisado:**
   La grilla de neuronas del SOM aprenderá a distribuir el espacio de estados normales del subsistema. Los patrones de funcionamiento habitual se concentrarán de forma densa en neuronas específicas del mapa .
3. **Visualización de estados anómalos:**
   Al proyectar nuevos instantes temporales sobre el mapa entrenado, las fallas y eventos extremos activarán neuronas más dispersas, permitiendo a los operadores visualizar claramente en qué "zona" del mapa cae el satélite en cada momento y cómo transiciona de un estado saludable a un estado de falla.

Paso 6: Evaluación de resultados

1. Contraste con los datos etiquetados:

Se comparan las banderas de alarma (C^t) generadas por el modelo con los rangos de tiempo certificados en el archivo labels.csv de la ESA.

2. Matriz de Confusión (2×2):

Se contabilizan:

- **Verdaderos Positivos (TP):** falla real que fue correctamente detectada por el modelo.

- **Falsos Positivos (FP):** falsa alarma (el modelo alertó anomalía cuando el satélite operaba normalmente).
- **Falsos Negativos (FN):** falla real que el modelo no detectó (situación crítica en operaciones espaciales).
- **Verdaderos Negativos (TN):** períodos normales sin falsas alertas.

3. Medidas de desempeño:

Precisión: $P = \frac{TP}{TP+FP}$ (confiabilidad de las alarmas).

Sensibilidad: $S +=\frac{TP}{TP+FN}$ (capacidad de cobertura de fallas).

F1-Score: Media armónica entre Precisión y Sensibilidad:

$$F1 = 2 \cdot \frac{P \cdot S+}{P + (S+)}$$

4. Gráficos de Resultados:

Se generarán paneles gráficos sincronizados en el tiempo que muestren:

- Serie temporal real vs. curva de predicción del modelo.
- Curva de error residual suavizado cruzando la línea de umbral.
- Franjas sombreadas de las anomalías reales (`labels.csv`) demostrando la coincidencia temporal de la detección.

Bibliografía

https://zenodo.org/records/15237121?preview_file=ESA-Mission1.zip Dataset de Agencia Espacial Europea (de donde provienen los datos)
https://dl.acm.org/doi/10.1145/3219819.3219845: LSTM aplicado
https://scholar.google.com.py/citations?view_op=view_citation&hl=es&user=RcnJ168AAAAJ&citation_for_view=RcnJ168AAAAJ:3fE2CSJIrl8C: Redes RNN aplicadas
https://proceedings.neurips.cc/paper_files/paper/2018/hash/8f468c873a32bb0619eaeb2050ba45d1-Abstract.html metricas de precision y recall por MIT
https://ieeexplore.ieee.org/document/6319708 EWMA
https://proceedings.neurips.cc/paper_files/paper/2018/file/8f468c873a32bb0619eaeb2050ba45d1-Paper.pdf Precision y recall del MIT (es el pdf del de más arriba)
https://www.researchgate.net/publication/313992620_The_Exponentially_Weighted_Moving_Average EWMA
Hay más bibliografía en pdf que se adjuntará en el repositorio de github.

Trabajo Inspiración y algunas ideas

Nuestra idea surge del interés por lo aeroespacial, luego de definir que era nuestro principal enfoque, se comenzó con la búsqueda de información al respecto por la red.
Allí, nos encontramos con el siguiente trabajo y repositorio:

- https://github.com/khundman/telemanom
- https://arxiv.org/abs/1802.04431

De aquí, sacamos la idea de utilizar Redes Recurrentes del tipo LSTM, la decisión no fue directa, sino que tuvimos que buscar información al respecto para entender el por qué utilizarlas y cómo hacerlo (se incluye en la bibliografía).
Además, vimos los conceptos de EWMA (**Exponentially Weighted Moving Average)** para suavizar las lecturas con respecto al tiempo (se explica más arriba).

Con esta primera visión y con el uso de herramientas de Inteligencia Artificial, nos dedicamos primero a entender los pormenores del funcionamiento de la red neuronal que vamos a aplicar, para poder entender el mecanismo que se usó en el github que adjuntamos más arriba y como estaban distribuidos los datos en nuestra Base de Datos, ya que, filtrar y analizar 12GB de datos, en mediciones de 90 seg entre sí era un trabajo que nos iba a implicar un tiempo considerable, por lo que, utilizamos a la IA para facilitar esto (saber distribución de datos y encontrar períodos con más anomalías para realizar un entrenamiento y análisis más eficaz).